

中国移动专利申请 技术交底书

公司编号	
发明名称	基于注意力语义感知的静默 KV 缓存淘汰与原位压缩的方法、装置、芯片及介质
申报单位	研究院
申报类型	发明
发明人	许达
技术联系人	许达 (xudayj@chinamobile.com, +86-13521894156)
注意事项	1. 技术联系人应为深入了解本申请提案技术方案的技术人员。 2. 请按照集团公司提供的本技术交底书模板逐项填写。

一、 发明名称

基于注意力语义感知的静默 KV 缓存淘汰与原位压缩的方法、装置、芯片及介质

二、 技术领域

本发明涉及人工智能计算、计算机体系结构与存储器管理技术领域，尤其涉及面向包含自注意力机制的神经网络推理（例如 Transformer 大模型推理）的显存/存储层级管理方法与装置，具体为一种在硬件侧旁路获取注意力分数（snoop）并据此实现 KV Cache（键值缓存）静默淘汰（eviction）与原位压缩（in-place compression）的语义感知内存管理单元（Semantic-MMU）。

与量子计算的关联说明：

本发明不涉及量子计算。本字段与其标题沿用模板格式，按模板要求保留。与之对应地，本发明所处的技术背景为：大模型推理正从“算力瓶颈”转向“显存墙与数据调度瓶颈”。在长上下文（10 万至百万 token）与多会话并发推理场景下，KV Cache 的容量、带宽、碎片与软件调度开销成为最致命的限制因素。现有 GPU/加速器多数依赖软件实现 KV 的分页管理、压缩与淘汰，导致额外 kernel、同步点与内存搬移，引入显著的尾延迟抖动。本发明采用“算法硅化”思路，将注意力语义信号用于底层存储管理，减少或消除软件参与。

本发明可应用于：

- 云端/端侧大模型推理加速器的长上下文推理与多并发推理
- 流式对话、RAG 检索增强生成、长文档摘要等长序列推理场景
- 需要稳定尾延迟与高吞吐的在线推理服务
- 在固定显存/片上 SRAM 约束下提升有效上下文长度的设备

关联项目：_____（待填写）

三、 现有技术的技术方案

3.1 量子计算网络安全背景

本节标题沿用模板。对应到本发明的现有技术背景为：Transformer 推理通常包含计算核心阵列、片上网络（NoC）、片上 SRAM 与外部显存（HBM/GDDR/LPDDR）等层级。推理过程中，KV Cache 为跨 token 的长期状态，其规模随上下文近似线性增长，并在多层多头注意力中被频繁访问。注意力访问呈现显著的动态热点：少数 token 被高频复用，更多历史 token 的注意力贡献长期处于低值。

为控制 KV 的容量与带宽压力，行业常见技术方案包括：

- **分页式/块式 KV 管理**：按页或块分配 KV，软件维护页表与回收策略，降低碎片但增加调度开销；
- **流式与窗口化**：滑动窗口、注意力 sink 等方式丢弃或稀疏化部分历史 token；
- **KV 压缩/量化**：将 KV 从 FP16/BF16 压缩至 INT8/INT4 或采用分组量化减少带宽；
- **软件整理与搬移**：为获得连续空间或提升局部性，触发搬移与重排，带来同步与拷贝。

3.2 后量子密码技术现状

本节标题沿用模板。对应到本发明的现有技术现状为：上述 KV 管理、淘汰与压缩方案大多由软件在计算核心（GPU SM/NPU 核）与 CPU 之间协同完成。虽然可在一定程度上延长上下文与降低显存压力，但普遍存在下列问题：

1. 需要额外 kernel 统计、排序或维护元数据，消耗计算资源并产生同步点；
2. 淘汰与压缩属于突发性重负载操作，易导致在线推理尾延迟显著波动；
3. 与推理框架或运行时耦合，跨平台迁移与适配成本高；
4. 缺乏低成本的硬件语义输入通路，难以在“数据搬运路径”内做出淘汰与压缩决策。

四、 现有技术的缺点及本申请提案要解决的技术问题

现有技术存在如下缺陷：

1. **软件侧统计与决策开销大：**注意力分数在计算核心内产生，软件若要基于其进行热度统计与淘汰决策，往往需要额外写回、归并与排序，造成显著开销；
2. **对上层不透明或侵入性强：**很多方案需要改动框架/运行时，引入工程风险并限制复用；
3. **尾延迟抖动明显：**压缩、碎片整理与回收通常以批处理方式触发，导致抖动；
4. **回收与重映射复杂：**软件维护页表/元数据一致性成本高，且常伴随搬移；
5. **无法在硬件侧持续衰减：**缺乏硬件级热度衰减计数器与阈值比较，难以实现低成本、持续在线的生命周期管理。

因此，本申请提案要解决的技术问题是：在不改变上层推理框架编程模型的前提下，如何在硬件侧静默地旁路获取注意力语义信息、维护 token 热度衰减计数器，并据此实现 KV Cache 的静默淘汰与原位压缩，同时提供透明重映射与一致性保障，从而显著提升有效上下文长度、吞吐与尾延迟稳定性。

五、 本申请提案的技术方案的详细阐述

5.1 系统架构

本发明系统包括如下模块：

1. **注意力旁路获取接口（Attention Snoop Tap）：**在片上互连/总线层对注意力分数或其统计量进行旁路捕获，并将其与 token 逻辑标识关联；

2. **语义感知内存管理单元 (Semantic-MMU)**: 部署于内存控制器或片上缓存/显存路径边界, 接收语义信号并输出淘汰/压缩/解压控制;
3. **Token 热度表与衰减计数器 (Heat Table)**: 为 token 维护热度计数、衰减、阈值比较与优先级信息;
4. **静默淘汰与回收引擎 (Silent Evict/Reclaim Engine)**: 在后台回收低热度 token 对应的 KV 物理块, 维护空闲链表与碎片合并;
5. **原位压缩引擎 (In-place Compression Engine)**: 对中等热度 KV 块执行原位量化/打包存储, 并支持按需解压;
6. **透明重映射与一致性模块 (Transparent Remap & Consistency)**: 维护“语义页表/元数据版本”, 对上层提供稳定逻辑视图, 确保淘汰、压缩与解压一致性;
7. **可观测性计数器与日志缓冲区**: 输出淘汰次数、压缩次数、回收字节数、解压命中等指标, 支持取证与调参。

5.2 核心方法步骤

5.2.1 1. 分布式密钥生成 (KeyGen)

本节标题沿用模板。对应到本发明的方法步骤为: 在推理会话初始化或上下文窗口建立时, Semantic-MMU 为每个 token 的 KV 块建立元数据记录, 包括物理块指针、压缩状态标志、热度计数器初值、版本号、以及可配置阈值 (淘汰阈值、压缩阈值、衰减周期与回收预算)。该初始化步骤可由驱动以一次或少量配置写入完成, 后续运行无需软件持续介入。

5.2.2 2. 消息哈希与映射

本节标题沿用模板。对应到本发明的方法步骤为: Semantic-MMU 对注意力旁路信号进行标识映射。具体地, 将注意力分数 (或聚合统计量, 例如跨头最大值、top-k 贡献和、滑动均值等) 与 token 的逻辑标识 (layer/head/token index/session id) 绑定, 并映射到 Heat Table 表项。映射可采用直接索引或哈希分桶, 以降低元数据存储规模与冲突。

5.2.3 3. 分布式高斯采样

本节标题沿用模板。对应到本发明的方法步骤为：Semantic-MMU 对热度计数器执行持续衰减与在线更新。可采用指数衰减与定点近似实现，例如：

$$H \leftarrow \alpha \cdot H + \beta \cdot S$$

其中 S 为旁路语义贡献， $\alpha \in (0, 1)$ 为衰减系数， β 为增益系数。为避免热度长期“锁死”，还可引入概率式采样更新，使冷 token 更快进入淘汰/压缩候选集合，且硬件开销保持极低。

5.2.4 4. 基于 NTT 的线性变换

本节标题沿用模板。对应到本发明的方法步骤为：当热度低于压缩阈值但高于淘汰阈值时，触发原位压缩引擎对 KV 块执行表示转换与打包存储，例如分组量化、缩放因子生成、离群值处理与 packing。该过程抽象为：

$$(\mathbf{K}, \mathbf{V}) \rightarrow \text{Pack}(\text{Quant}(\mathbf{K}), \text{Quant}(\mathbf{V}), \text{Scale})$$

并在同一物理块或预留邻接块中就地写回，避免生成临时张量与大规模搬移。

5.2.5 5. 基于 Beaver 三元组的安全范数验证

本节标题沿用模板。对应到本发明的方法步骤为：为保证压缩与淘汰不会破坏推理正确性与一致性，Semantic-MMU 维护轻量校验元数据与误差界信息，例如 CRC/校验和、量化误差上界估计、缩放因子范围、版本号等，并在解压或关键访问路径执行快速一致性检查。若校验失败或误差界超出策略阈值，则对该 KV 块执行回退策略（例如强制保留高精度、禁止再次压缩、提升热度），以保证系统稳定性。

5.2.6 6. 动态节点管理

本节标题沿用模板。对应到本发明的方法步骤为：在运行期，当显存压力达到阈值或回收预算触发时，Semantic-MMU 在后台静默选择低热度 token 的 KV 物理块执行淘汰：释放物理块、维护空闲链表、合并空洞并更新语义页表；对仍需保留的历史 token，可保留压缩态或下沉到更低速存储层。整个过程不触发软件中断，不引入显式同步点，对上层框架保持透明。

六、 本申请提案的关键点和欲保护点

本申请提案主要包含以下关键创新点和保护点：

1. **注意力语义旁路获取 (Bus/NoC Snoop)**: 在不增加计算核心负担的情况下旁路捕获注意力分数/统计量，并与 token 元数据绑定；
2. **硬件级热度衰减计数器**: 硬件侧持续维护 token 热度并进行阈值比较，输出淘汰与压缩决策；
3. **静默淘汰与回收状态机**: 在后台完成物理块回收与碎片合并，不阻塞主流水线；
4. **原位压缩与按需解压**: 对 KV 块执行原位量化打包，并在访问路径按需解压，降低显存与带宽；
5. **透明重映射与一致性保障**: 维护语义页表/版本控制，使上层以为 KV 逻辑地址稳定存在；
6. **可配置策略与可观测性**: 阈值、预算、优先级与回退策略可配置，并输出计数器用于调参与取证。

七、 与第三条中最接近的现有技术相比，本申请提案有何技术优点

相比于现有技术（如软件侧分页式 KV 管理、软件淘汰与软件压缩/整理等），本方案具有显著优势：

(1) **对上层框架透明**: 语义页表与元数据在硬件侧维护，上层无需引入额外管理逻辑。(2) **显著降低软件开销与尾延迟抖动**: 淘汰回收与压缩在硬件后台执行，避免突发性软件整理。(3) **提高显存利用率与有效上下文长度**: 低热度 KV 被回收，中等热度 KV 原位压缩，固定显存下可显著扩大可支持上下文。(4) **带宽效率更高**: 压缩态降低 KV 读写带宽，热度驱动减少无效历史 token 访问。(5) **易落地**: 不依赖新材料与新工艺，主要为内存控制器、互连旁路与少量定点计算/状态机逻辑，可用成熟 CMOS 数字逻辑实现。

八、 其他有助于理解本申请提案的技术资料

(1) vLLM: PagedAttention(公开论文/开源实现)(2) FlashAttention / FlashAttention-2(公开论文/开源实现)(3) StreamingLLM / Attention Sinks(公开论文/开源实现)(4) 统一虚拟内存(UVM)与内存压缩相关公开资料(GPU/加速器白皮书与学术论文)

九、 本申请提案的侵权证据可获得性

本提案的侵权行为具有较高的可检测性：(1) **硬件接口与寄存器/计数器可观测性**：实现 Semantic-MMU 的加速器通常具有阈值、预算、策略等可配置寄存器，以及淘汰/压缩/解压等性能计数器，可通过驱动/SDK 识别。(2) **微架构结构性证据**：芯片/固件分析中若存在注意力分数旁路通路、token 热度表、后台回收状态机与原位量化打包逻辑，可形成强结构证据。(3) **行为侧证（性能曲线）**：在长上下文压力测试下呈现“显存接近满载但尾延迟稳定、且 KV 压缩态切换与带宽曲线相关”的特征，可作为侵权线索。